

TRI FUSION (« MERGE SORT »)

INTRODUCTION

Diviser pour régner

C'est algorithme est une illustration du principe algorithmique « diviser pour régner ».

La résolution se fait en trois étapes :

1. division du problème en un certain nombre de sous-problèmes ;
2. résolution des sous-problèmes récursivement ;
3. assemblage des solutions des sous-problèmes.

Dans le tri fusion

Si A est un tableau de longueur n .

1. On divise A en deux tableaux A_1 et A_2 de longueur divisée par deux ;
2. on trie A_1 et A_2 ;
3. on fusionne les deux tableaux A_1, A_2 triés.

1. FUSION DE DEUX TABLEAUX TRIÉS

1.1. Principe

On se donne deux tableaux triés A, B . L'objectif est d'obtenir C tel que $|C| = |A| + |B|$ et tel que C soit la fusion triée de A et B .

Exemple. — Si $A = (1, 2, 3, 7, 9, 11)$ et $B = (2, 4, 5, 13)$ alors $C = (1, 2, 2, 3, 4, 5, 7, 9, 11, 13)$.

Principe. — Si C est indicé par k allant de 0 à $n + m - 1$ (avec $n = |A|, m = |B|$), alors :

1. on maintient i et j positions respectives dans A et B et on compare $A[i]$ et $B[j]$;
2. on insère le plus petit des deux dans la liste C et on augmente le compteur concerné de 1 ;
3. cas spécial quand l'un des deux tableaux est déjà trié (auquel cas aucune comparaison n'est nécessaire, on adjoint simplement).

```

1 function Merge(A,B)
2     n = longueur(A) , m = longueur(B)
3     i = 0 , j = 0
4     for k from 0 to n+m-1 do
5         if i > n-1 then
6             C[k] = B[j] , j = j+1
7             continue
8         if j > m-1 then
9             C[k] = A[i] , i = i+1
10            continue
11        if A[i] > B[j] then
12            C[k] = B[j] , j = j+1
13        else
14            C[k] = A[i] , i = i+1
15    return C

```

1.2. Preuve de correction

PROPOSITION 1.2.0.1 (Invariant). —

Soit $[[k]], [[i]], [[j]]$ les valeurs respectives des variables k, i, j avec $[[k]] = [[i]] + [[j]]$. À l'issue d'une itération de la boucle *for*, les indices de 0 à $[[k]] - 1$ de C contiennent les éléments de :

- A entre 0 et $[[i]] - 1$,
- B entre 0 et $[[j]] - 1$,

et triés dans l'ordre croissant.

DÉMONSTRATION 1.2.0.1. —

On procède par récurrence sur k :

- Pour $[[k]] = 1$ c'est clair.
- Si $[[k]] - 1$ indices sont vérifiés, alors $[[k]]$ -ième est :

$$C[k] = \min \{A[i], B[j]\} = \min \{A[h] : i \leq h \leq n - 1, B[k] : j \leq k \leq n - 1\}.$$

La propriété est bien vérifiée.

1.3. Complexité

On évalue le nombre de comparaisons.

- On effectue au plus trois comparaisons par itération, si $C(n)$ est le nombre de comparaisons :

$$C(n) = O(n + m), C(n) = \Omega(n + m).$$

2. ALGORITHME POUR LE TRI FUSION

2.1. Algorithme

```
1 function MergeSort(A)
2     n = longueur(A)
3     if n <= 0 then return A
4     m = int((n-1)/2)
5     A1 = A[0 : m-1]
6     A2 = A[m : n-1]
7     A1 = MergeSort(A1)
8     A2 = MergeSort(A2)
9     A = Merge(A1, A2)
10    return A
```

Illustration. — Par exemple :

$(7 \ 3 \ 4 \ 8 \ 2 \mid 15 \ 5 \ 6)$
 $\rightarrow (7 \ 3 \mid 4 \ 8) \ (2 \ 15 \mid 5 \ 6)$
 $\rightarrow (7 \ 3) \ (4 \ 8) \ (2 \ 15) \ (5 \ 6)$
 $\rightarrow (7) \ (3) \ (4) \ (8) \ (2) \ (15) \ (5) \ (6) \text{ (fin division)}$
 $\rightarrow (3 \ 7) \ (4 \ 8) \ (2 \ 15) \ (5 \ 6)$
 $\rightarrow (3 \ 4 \ 7 \ 8) \ (2 \ 5 \ 6 \ 15)$
 $\rightarrow (2 \ 3 \ 4 \ 5 \ 6 \ 7 \ 8 \ 15) \text{ (fin fusion)}$

2.2. Complexité

Soit $C(n)$ le nombre de comparaisons pour l'algorithme de tri fusion. Alors

$$C(n) = C(\lfloor n/2 \rfloor) + C(\lceil n/2 \rceil) + n - 1 \text{ (1§)}$$

1§. Avec un algorithme plus performant pour la fusion on peut avoir un coût de $n - 1$.

THÉORÈME 2.2.0.1. —

Si A est un tableau de longueur n , alors le nombre de comparaisons, $C(n)$, effectuées par le tri fusion est de $O(n \log n)$ dans le pire des cas.

C'est un cas particulier du « MASTER Theorem ».

DÉMONSTRATION 2.2.0.2. —

On cherche à majorer la suite (t_n) définie par $t_0 = t_1 = 0$ et

$$t_n \leq n - 1 + t_{\lfloor n/2 \rfloor} + t_{\lceil n/2 \rceil}.$$

On suppose d'abord que $n = 2^k$ pour un certain $k \in \mathbf{N}$. On étudie (u_k) telle que $u_0 = u_1 = 0$ et :

$$u_{k+1} = 2^{k+1} - 1 + 2u_k.$$

On peut montrer que le terme général de cette suite est :

$$u_k = (k - 1)2^k + 1.$$

On a donc

$$t_{2^k} \leq u_k = (k - 1)2^k + 1.$$

Soient $n \in \mathbf{N}^*$ et $k \in \mathbf{N}^*$ tels que

$$2^k < n \leq 2^{k+1} - 1.$$

Montrons que $t_n \leq u_{k+1}$:

- pour $n = 2$ c'est vérifié, $2^0 < n \leq 2^1$ et $t_2 = u_1$;
- supposons que c'est montré pour $n + 1$ tel que $2^k < n + 1 \leq 2^{k+1}$, on a

$$t_{n+1} \leq n + t_{\lfloor n/2 \rfloor} + t_{\lceil n/2 \rceil}$$

or $\lceil (n + 1)/2 \rceil \leq 2^k \leq n$ et donc

$$t_{n+1} \leq 2^{k+1} - 1 + u_k + u_k$$

et donc

$$t_{n+1} \leq u_{k+1}.$$

Ainsi, si k est tel que $2^k < n \leq 2^{k+1}$ alors

$$t_n \leq u_{k+1} = k2^{k+1} + 1$$

c'est-à-dire :

$$t_n < (2n) \log_2(n) + 1.$$